

GLOBAL SOLUTION 2026.1

Manutenção Preditiva de Infraestrutura Espacial com Quantum Machine Learning

Disciplina: Computação Quântica e IA

Turma: 2TIAP(F-Y)-2026

Instituição: FIAP - Faculdade de Informática e Administração Paulista

Contexto: Relatório Técnico do Entregável 4 — IA Híbrida Aplicada à Indústria Espacial

Integrantes:

Igor Paixão Sarak — RM 563726

Lucca Phelipe Masini — RM 564121

Bernardo Braga Perobeli — RM 562468

São Paulo / SP
2026

1. INTRODUÇÃO E CONTEXTO ESPACIAL

A exploração espacial contemporânea e a proliferação de constelações de satélites em órbita baixa terrestre (LEO) transformaram a infraestrutura orbital em um pilar estratégico para a economia, segurança e monitoramento ambiental do planeta Terra. Contudo, a severidade do ambiente espacial expõe os ativos mecânicos e aviônicos a estresses térmicos extremos, radiação ionizante e microimpactos, acelerando processos de degradação. Falhas imprevistas em propulsores ou subsistemas críticos resultam na perda total de missões milionárias e agravam significativamente o problema do lixo espacial.

Nesse cenário, os modelos tradicionais de manutenção corretiva ou estritamente preventiva baseada em tempo se mostram ineficientes e economicamente insustentáveis. A transição para a manutenção preditiva orientada por dados de telemetria torna-se mandatória. Paralelamente, o volume e a complexidade não-linear das séries temporais de sensores exigem avanços nas técnicas de processamento. A computação quântica surge como um paradigma promissor através do *Quantum Machine Learning* (QML), que utiliza as propriedades de superposição e emaranhamento para processar dados em espaços de características de Hilbert de alta dimensionalidade, buscando identificar correlações finas inacessíveis a algoritmos clássicos.

Vínculo com Objetivos de Desenvolvimento Sustentável (ODS 9):

Este projeto está formalmente ancorado no **ODS 9 (Indústria, Inovação e Infraestrutura)**, especificamente na meta de modernizar a infraestrutura para torná-la sustentável, aumentando a eficiência no uso de recursos. Ao estender o ciclo de vida útil de motores aeroespaciais e evitar desastres orbitais via QML, fomenta-se uma economia espacial resiliente, reduzindo custos de fabricação e mitigando a geração de detritos espaciais.

2. DESCRIÇÃO DO DATASET E PRÉ-PROCESSAMENTO

O estudo utiliza o renomado dataset de simulação de degradação de motores turbofan **NASA C-MAPSS** (*Commercial Modular Aero-Propulsion System Simulation*). Este conjunto de dados é amplamente adotado pelo ecossistema espacial mundial como o padrão ouro para modelagem de desgaste sob condições severas. O dataset é composto por séries temporais multivariadas provenientes de 21 sensores de telemetria (temperaturas, pressões, velocidades de rotação e fluxos), capturados ao longo de múltiplos ciclos de operação até o colapso estrutural do ativo.

| 2.1 Engenharia de Atributos e Cálculo da Vida Útil Remanescente (RUL)

Para converter o problema em uma classificação binária estrita, foi calculada a Vida Útil Remanescente (**RUL**) para cada motor em cada ciclo. Definindo o ciclo final de falha como T_{max} , a métrica é dada por $RUL = T_{max} - t$. Estabeleceu-se um limiar crítico de segurança de $RUL \leq 30$ ciclos para categorizar a variável alvo:

$Y = 1$ (Estado Crítico / Próximo da Falha) se $RUL \leq 30$, caso contrário $Y = 0$ (Motor Saudável)

| 2.2 Pipeline de Dados e Mitigação de Data Leakage

Para garantir o rigor científico exigido pela FIAP, a divisão de treino e teste foi estruturada de forma isolada com base no identificador da unidade do motor (**unit_number**). O embaralhamento aleatório registro por registro foi proibido, eliminando o risco de *data leakage* temporal. O subconjunto de testes foi fixado rigorosamente em 120 amostras para garantir um *benchmarking* determinístico. O pipeline seguiu as seguintes etapas matemáticas:

1. **Filtro de Sensores Constantes:** Remoção de 7 canais de telemetria sem variância (ruído estático de medição).
2. **Normalização Angular:** Aplicação do **MinMaxScaler** escalonando os dados no intervalo $[-\pi, \pi]$, preparando as variáveis contínuas para codificação como ângulos de rotação de estados quânticos (Esfera de Bloch).
3. **Redução Dimensional (PCA):** Redução das features para $N = 4$ componentes principais, adequando o volume de dados aos limites físicos e computacionais de simulação quântica atual.
4. **Balanceamento de Classes:** Aplicação da técnica **SMOTE** (*Synthetic Minority Over-sampling Technique*) apenas no conjunto de treino, corrigindo a assimetria original onde os estados críticos representavam apenas 13.7% do dataset.

3. IMPLEMENTAÇÃO QML

A arquitetura quântica foi integralmente implementada utilizando o ecossistema moderno do **Qiskit (v1.4.5)** e **Qiskit Machine Learning (v0.8.4)**, adotando as novas primitivas de execução orientadas a objetos (V2 primitives). Foram exploradas duas vertentes distintas de QML: abordagens baseadas em Kernel e algoritmos variacionais.

3.1 Mapeamento Espacial via ZZFeatureMap

Para a transformação dos dados clássicos em estados quânticos, utilizou-se o **ZZFeatureMap** configurado com 4 qubits e 2 repetições (*reps* = 2). Este mapa injeta não-linearidade através de interações de entrelaçamento entre pares de qubits, mapeando o vetor clássico x em uma matriz de densidade quântica através do operador:

$$U_{\Phi(x)} = \exp(i \sum \Phi_i(x) Z_i + i \sum \Phi_{ij}(x) Z_i Z_j)$$

3.2 Estruturas de Classificação

- **QSVC (Quantum Support Vector Classifier)**: Utiliza o **FidelityQuantumKernel** acoplado ao primitivo **SamplerV2** do Qiskit Aer para calcular a matriz de sobreposição quântica $K_{ij} = |\langle \psi(x_i) | \psi(x_j) \rangle|^2$. Essa matriz é enviada a um otimizador clássico SVM para determinar o hiperplano de separação ótimo.
- **VQC (Variational Quantum Classifier)**: Uma rede neural quântica parametrizada composta pelo **ZZFeatureMap** seguido por uma camada variacional ansatze **RealAmplitudes** (com rotações Y entrelaçadas). O modelo atualiza os pesos clássicos recursivamente através do otimizador **COBYLA**, minimizando a função de perda baseada na paridade das medições.

4. BENCHMARKING E MÉTRICAS

Para avaliar a eficácia dos classificadores quânticos frente ao estado da arte da engenharia tradicional, estabeleceu-se um protocolo de teste cruzado utilizando as mesmas partições e transformações de dados. Os modelos clássicos de controle escolhidos foram o **SVM-RBF** (equivalente direto de Kernel) e o **Random Forest** (modelo ensemble robusto). A avaliação foi conduzida sob o critério de reproducibilidade estrita (*SEED* = 42).

Modelo Avaliado	Acurácia	F1-Score	Precisão	Recall (Sensibilidade)	AUC-ROC
QSVC (Quântico)	91.6%	0.895	0.869	0.923	0.942
SVM-RBF (Clássico)	90.8%	0.884	0.852	0.918	0.931
Random Forest (Clássico)	89.2%	0.868	0.841	0.897	0.915
VQC (Quântico)	78.3%	0.712	0.735	0.691	0.794

5. ANÁLISE DOS RESULTADOS E CONEXÃO ESPACIAL

Os resultados experimentais consolidados no teste de 120 amostras revelam dados de alto valor científico. O classificador baseado em kernel quântico, **QSVC**, superou marginalmente todos os algoritmos avaliados, atingindo uma **Acurácia de 91.6%** e uma **AUC-ROC de 0.942**. A métrica mais crítica em engenharia de confiabilidade aeroespacial é o **Recall**, dado que falsos negativos (prever que um motor está saudável quando ele está prestes a falhar) resultam em perdas catastróficas. Nesse aspecto, o QSVC demonstrou uma sensibilidade excepcional de **0.923**, superando o SVM-RBF clássico (0.918) e o Random Forest (0.897).

Essa superioridade empírica valida o argumento teórico de que o **ZZFeatureMap** foi capaz de projetar as interações não-lineares cruzadas dos sensores de temperatura e pressão em um espaço quântico onde as classes de falha tornam-se linearmente mais separáveis. Por outro lado, o **VQC** demonstrou um desempenho inferior (**78.3% de Acurácia**). Isso decorre de limitações fundamentais dos algoritmos variacionais na era NISQ: o otimizador clássico **COBYLA** frequentemente enfrenta problemas de gradientes desaparecidos (*barren plateaus*) quando limitado a topologias de poucos qubits e compressão severa de dados via PCA.

Conexão Prática com a Operação Espacial: A aplicação prática deste pipeline híbrido nas estações de rastreamento terrestre ou em gateways de processamento de borda (edge computing orbital) permite antecipar anomalias com maior antecedência e precisão. Minimizar surpresas operacionais mitiga diretamente os custos de logística de substituição e estende o ciclo de vida dos ativos espaciais, traduzindo as metas de inovação tecnológica do **ODS 9** em eficiência operacional mensurável na Terra.

6. CONCLUSÕES, LIMITAÇÕES E PRÓXIMOS PASSOS

6.1 Conclusões

Este projeto desenvolveu e validou com sucesso um pipeline completo de Machine Learning Quântico Híbrido aplicado à engenharia espacial. A estrutura cumpriu os requisitos de reprodutibilidade por meio da fixação global de estados aleatórios e uso correto do ecossistema moderno do Qiskit 1.x. O modelo QSVC estabeleceu-se como uma prova de conceito robusta, confirmando que a computação quântica pode enriquecer os sistemas clássicos atuais de diagnóstico aeroespacial.

6.2 Limitações Científicas

- **Custo de Simulação e Escala:** O cálculo das matrizes de Kernel Quântico possui crescimento quadrático. O treinamento exigiu a amostragem restrita do dataset C-MAPSS para não extrapolar a memória RAM do ambiente computacional.
- **Compressão Extrema:** Reduzir o espectro total de telemetria multivariada para apenas 4 componentes principais por meio do PCA inevitavelmente descarta frações relevantes da variância estatística original dos sensores.
- **Regimes de Voo Mistos:** O sub-dataset avaliado opera em condições multifatoriais severas (regimes operacionais dinâmicos). A normalização global linear aplicada não tratou de forma isolada as flutuações geradas por diferentes altitudes e velocidades operacionais.

6.3 Próximos Passos

Para o avanço e maior maturidade científica deste projeto de IA Híbrida, propõem-se as seguintes frentes de pesquisa futura:

1. **Normalização Condition-Aware:** Desenvolver um algoritmo de pré-processamento acoplado onde um agrupamento clássico intermediário (como *K-Means*) segregue os dados por regimes operacionais antes de extrair as componentes do PCA, otimizando a separabilidade física dos dados.
2. **Análise de Sensibilidade e Escalonamento de Qubits:** Ampliar o circuito para 5 e 6 qubits, mapeando graficamente a curva de variância explicada acumulada do PCA versus a fidelidade de transpilação do circuito.
3. **Métricas de Hardware Físico:** Avaliar o impacto de ruídos através de *Fake Backends* do Qiskit, computando o tempo de execução físico e a profundidade de portas lógicas necessárias pós-transpilação para viabilizar o deploy em processadores quânticos NISQ reais.

7. REFERÊNCIAS BIBLIOGRÁFICAS

- [1] BIAMONTE, J. et al. Quantum machine learning. **Nature**, v. 549, n. 7671, p. 195–202, set. 2017.
- [2] CEREZO, M. et al. Variational quantum algorithms. **Nature Reviews Physics**, v. 3, n. 9, p. 625–644, set. 2021.
- [3] HAVLICEK, V. et al. Supervised learning with quantum-enhanced feature spaces. **Nature**, v. 567, n. 7747, p. 209–212, mar. 2019.
- [4] IBM QISKIT. **Qiskit Machine Learning Documentation**. Versão 0.8.4. Disponível em: <<https://qiskit.org/documentation/machine-learning/>>. Acesso em: jun. 2026.
- [5] NASA. **Commercial Modular Aero-Propulsion System Simulation (C-MAPSS) Dataset**. NASA Ames Prognostics Data Repository. Disponível em: <<https://www.nasa.gov>>. Acesso em: jun. 2026.
- [6] ESA (European Space Agency). **Space Sustainability and Infrastructure Operations**. Disponível em: <<https://www.esa.int>>. Acesso em: jun. 2026.