

ASSISTENTE PARA PROJETO DE EDIFÍCIOS EFICIENTES QUANTO A ÁGUA E ENERGIA

Refletir sobre o contexto da nova economia espacial é uma grande meta, a qual deveria ser iniciada pensando e tratando problemas simples e comuns enfrentados todos os dias pelos habitantes deste planeta. O consumo exagerado sem crivos de eficiência, economia e reuso de benefícios simples como água e energia, nos obriga a repensar como otimizar o uso destes insumos dos quais nossas vidas tanto dependem, para então aplicar estes novos padrões em futuros desbravamentos espaciais. Embora existam atualmente diversas certificações ambientais e regras para construção verde e sustentável, a crescente disponibilidade de documentos técnicos sobre o tema contrasta com a dificuldade de encontrar respostas precisas e rastreáveis sobre o tema. Modelos de linguagem generalistas como GPT, Claude e Llama conhecem superficialmente conceitos como LEED, AQUA-HQE e Net Zero, mas falham ao ser questionados sobre requisitos normativos específicos. Técnicas como RAG permitem superar essa limitação ao conectar o modelo a uma base de conhecimento construída pelo próprio desenvolvedor, tornando as respostas fundamentadas em documentos reais e auditáveis.

Seu objetivo neste desafio é construir, do zero, um **assistente técnico especializado em Edifícios Verdes e Net Zero de Energia e Água**, capaz de responder perguntas técnicas com precisão, citando sempre a fonte que embasou a resposta. O sistema poderá ser executado em ambiente local, sem depender de APIs externas pagas, ou em nuvem a critério do aluno. ***Importante:** as documentações escolhidas deverão orientar o interessado em como projetar e operar edifícios sustentáveis capazes de coletar e tratar água localmente e gerar energia via módulos fotovoltaicos ou outro sistema de geração, de modo que o edifício seja capaz de suprir metade ou todas suas necessidades de água e energia sem depender de fontes externas.*

O projeto integra os conceitos estudados em aula: construção de corpus, pré-processamento, chunking, geração de embeddings, indexação em banco vetorial e orquestração do pipeline RAG. O projeto deverá seguir a seguinte estrutura:

1 — Planejamento e escopo Definir o recorte temático dentro do universo de edifícios verdes e Net Zero — por exemplo, focar em eficiência energética, certificações, reúso de água ou em todos simultaneamente. Documentar a decisão e justificar as escolhas de tecnologia (modelo de embedding, banco vetorial e LLM).

2 — Construção do Corpus Reunir no mínimo 10 documentos técnicos sobre o tema, nos formatos PDF, TXT, DOCX ou HTML. O corpus deve contemplar ao menos três categorias distintas de fonte: normas ou guias de certificação (LEED, AQUA-HQE, GBC Brasil, ABNT NBR 15575), relatórios técnicos ou científicos (IEA, PROCEL, CBCS, artigos de periódicos) e manuais ou especificações de tecnologias habilitadoras (sistemas fotovoltaicos, BEMS, reaproveitamento de águas cinzas). Cada documento deve receber metadados mínimos: fonte, categoria, subcategoria (energia ou água), ano e indicação de vigência.

3 — Limpeza e normalização Extrair o texto de cada documento, remover ruídos típicos de PDFs técnicos — cabeçalhos e rodapés repetidos, números de página, referências bibliográficas isoladas — e normalizar encoding, espaços múltiplos e caracteres especiais. Preservar intactas as tabelas de parâmetros técnicos e os requisitos normativos numerados, pois fragmentá-los compromete a qualidade das respostas.

4 — Segmentação (chunking) Segmentar os documentos em chunks de 512 a 1024 tokens, respeitando a estrutura semântica dos documentos — seções, artigos e créditos de certificação não devem ser cortados no meio. Gerar um relatório com o total de chunks produzidos, a distribuição por categoria e o tamanho médio em tokens.

- 5 — Geração de embeddings e indexação** Gerar embeddings para todos os chunks usando um modelo open-source adequado ao português técnico. Indexar os vetores em um banco vetorial com persistência em disco (recomenda-se ChromaDB ou FAISS), armazenando os metadados junto a cada chunk para habilitar filtros por categoria durante a busca.
- 6 — Pipeline RAG com LLM local** Conectar o banco vetorial a um LLM de pequeno porte — modelos aceitos: Llama 3.2 3B, Qwen2.5 3B, Phi-4 Mini, Gemma 3 4B ou Mistral 7B (quantizado Q4). Implementar um prompt de sistema que instrua o modelo a responder exclusivamente com base nos chunks recuperados e a citar obrigatoriamente a fonte de cada informação técnica.
- 7 — Avaliação do sistema** Formular 10 perguntas técnicas sobre o corpus coletado e registrar as respostas do sistema RAG com as respectivas fontes citadas. Para cada resposta, verificar manualmente se a informação está de fato presente no documento indicado. Comparar pelo menos 3 dessas respostas com a saída do mesmo LLM **sem contexto RAG**, documentando as diferenças em precisão, rastreabilidade e ocorrência de alucinação.
- 8 — Relatório crítico** Elaborar um relatório de no mínimo 600 palavras analisando: dificuldades encontradas na coleta de documentos técnicos sobre o tema; qualidade dos clusters observados na visualização t-SNE; proporção de perguntas respondidas com sucesso versus perguntas sem cobertura no corpus; conclusões sobre o impacto do RAG na qualidade das respostas; e proposta de pelo menos duas melhorias que seriam implementadas com mais tempo.
-

Critérios de Avaliação

Qualidade do notebook contendo as etapas de criação do Corpus: pré-processamento, chunking, embeddings e indexação	30%
Qualidade do pipeline RAG funcional com LLM e citação de fontes	30%
Relatório crítico com 10 perguntas respondidas + comparação RAG vs LLM puro.	20%
Video apresentando sua solução	20%
